

LAPORAN PRAKTIKUM MACHINE LEARNING

**PERBANDINGAN MODEL MACHINE LEARNING DALAM PREDIKSI
RISIKO KREDIT: STUDI EKSPERIMEN XGBOOST DAN RANDOM
FOREST**



Oleh:

Rafki Sahasika Riyuda

09011182227007

**JURUSAN SISTEM KOMPUTER
FAKULTAS ILMU KOMPUTER
UNIVERSITAS SRIWIJAYA**

2025

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Dalam industri keuangan, penilaian risiko kredit menjadi salah satu faktor utama yang menentukan keberhasilan suatu lembaga dalam mengelola pinjaman. Risiko kredit merujuk pada kemungkinan debitur gagal memenuhi kewajibannya sesuai dengan ketentuan yang telah disepakati. Kredit macet, jika tidak dikelola dengan baik, dapat menimbulkan kerugian finansial yang signifikan bagi perbankan dan lembaga keuangan lainnya .

Dalam beberapa tahun terakhir, perkembangan teknologi kecerdasan buatan (AI) dan machine learning telah membuka peluang baru dalam menganalisis risiko kredit secara lebih akurat dan efisien. Berbagai algoritma pembelajaran mesin telah digunakan dalam tugas klasifikasi risiko kredit, di antaranya XGBoost (Extreme Gradient Boosting) dan Random Forest, yang dikenal memiliki performa unggul dalam menangani data yang kompleks dan tidak seimbang.

Melalui pemanfaatan dataset yang berisi informasi mengenai karakteristik peminjam, seperti usia, pendapatan, status kepemilikan rumah, dan tujuan pinjaman, model Machine Learning dapat membantu lembaga keuangan dalam membuat keputusan yang lebih tepat terkait persetujuan atau penolakan kredit. Penelitian sebelumnya telah menunjukkan bahwa model berbasis XGBoost dan Random Forest dapat memberikan hasil yang lebih baik dalam memprediksi risiko kredit, terutama dalam lingkungan dengan data yang tidak seimbang.

Dengan demikian, penelitian ini bertujuan untuk menganalisis dan membandingkan performa dari algoritma XGBoost dan Random Forest dalam memprediksi risiko kredit berdasarkan dataset yang telah dikumpulkan, yang akan memberikan wawasan lebih dalam bagi lembaga keuangan untuk mengambil keputusan yang lebih tepat dalam pengelolaan risiko kredit.

1.2. Rumusan Masalah

1. Bagaimana proses penerapan machine learning menggunakan algoritma XGBoost dan Random Forest dalam memprediksi risiko kredit?
2. Bagaimana perbandingan kinerja antara model XGBoost dan Random Forest dalam mengklasifikasikan apakah seorang peminjam berisiko gagal bayar atau tidak?
3. Faktor-faktor apa saja yang paling berpengaruh dalam penentuan risiko kredit berdasarkan interpretasi dan visualisasi pada masing-masing model?


1.3. Tujuan

1. Menganalisis dan menerapkan algoritma XGBoost dan Random Forest dalam klasifikasi risiko kredit.
2. Mengevaluasi dan membandingkan kinerja kedua model dengan menggunakan metrik evaluasi seperti akurasi, precision, recall, dan F1-score.
3. Mengidentifikasi factor-faktor yang memiliki pengaruh terbesar dalam menentukan risiko kredit berdasarkan interpretasi dan visualisasi dari masing-masing model guna membantu pengambilan keputusan oleh lembaga keuangan.

BAB 2

TAHAPAN PENELITIAN

2.1. Flowchart



2.2. Pemilihan Dataset

Tahap awal dalam proses ini adalah pemilihan dataset yang berkaitan dengan risiko kredit. Dataset ini berisi informasi penting seperti usia peminjam, pendapatan, status kepemilikan rumah, tujuan pinjaman, jumlah pinjaman, dan tingkat bunga. Pemilihan dataset ini didasarkan pada relevansi fitur-fitur tersebut dalam memprediksi kemungkinan terjadinya kredit bermasalah. Dataset yang tepat akan membantu proses analisis dan pemodelan berjalan dengan optimal.

2.3. EDA (Exploratory Data Analysis)

Setelah dataset dipilih, dilakukan proses EDA untuk memahami struktur dan karakteristik data. Analisis ini mencakup identifikasi nilai yang hilang, outlier, dan distribusi data. Selain itu, analisis korelasi antara variabel juga dilakukan untuk mengetahui hubungan antar fitur. Proses EDA ini penting untuk memberikan gambaran awal terkait kualitas data dan potensi permasalahan yang mungkin muncul di tahap selanjutnya.

2.4. Data Preprocessing

Tahap ini berfokus pada pembersihan dan persiapan data agar dapat digunakan dengan optimal oleh model machine learning. Langkah-langkah yang dilakukan meliputi penanganan data yang hilang, penghapusan outlier, serta encoding variabel kategorikal menjadi numerik. Normalisasi atau penskalaan fitur juga dapat dilakukan untuk memastikan semua variabel memiliki skala yang seragam. Proses preprocessing ini bertujuan untuk menghasilkan data yang bersih dan siap digunakan dalam pelatihan model.

2.5. Pemisahan Data

Setelah data siap, dataset akan dibagi menjadi dua bagian utama, yaitu data pelatihan (training data) dan data pengujian (testing data). Umumnya, pembagian ini menggunakan rasio 80:20, di mana 80% data digunakan untuk melatih model dan 20% sisanya digunakan untuk menguji kinerja model. Atau dengan 70:15:15, di mana 70% data digunakan untuk melatih model, 15% untuk menguji kinerja model dan 15% sisanya untuk validasi kinerja model. Tahap ini bertujuan untuk menghindari overfitting dan memastikan bahwa model dapat memprediksi data baru dengan baik.

2.6. Pelatihan Model

Pada tahap ini, model XGBoost akan dilatih menggunakan data pelatihan. XGBoost dipilih karena kemampuannya dalam menangani dataset yang kompleks dengan efisien dan akurat. Proses pelatihan melibatkan penyesuaian parameter model untuk mendapatkan performa terbaik. Model akan belajar dari pola-pola yang ada di data pelatihan sehingga dapat digunakan untuk melakukan prediksi pada data baru.

2.7. Evaluasi Hasil

Evaluasi model dilakukan menggunakan data pengujian untuk mengukur seberapa baik model yang telah dilatih. Berbagai metrik evaluasi, seperti akurasi, precision, recall, dan F1-score, akan digunakan untuk menilai kinerja model. Hasil evaluasi ini akan menunjukkan apakah model dapat memprediksi risiko kredit dengan akurat dan andal. Jika diperlukan, proses tuning parameter dapat dilakukan untuk meningkatkan performa model.

2.8. Interpretasi dan Visualisasi

Tahap terakhir adalah interpretasi dan visualisasi fitur untuk mengidentifikasi factor apa yang memiliki pengaruh paling signifikan dalam proses prediksi. Dengan memanfaatkan fitur feature importance dari model XGBoost dan Random Forest, dapat dilihat seberapa besar kontribusi masing-masing fitur terhadap hasil prediksi. Visualisasi seperti bar chart atau ROC digunakan untuk mempermudah pemahaman terhadap hasil interpretasi. Langkah ini penting untuk memberikan wawasan mendalam bagi pengambilan keputusan oleh lembaga keuangan berdasarkan faktor risiko yang dominan.

BAB 3

PEMILIHAN TOPIK DAN DATASET

3.1. Pemilihan Topik

Topik yang diangkat dalam proyek ini adalah klasifikasi risiko kredit menggunakan algoritma XGBoost (Extreme Gradient Boosting) dan Random Forest. Risiko kredit menjadi elemen yang sangat penting dalam sektor perbankan dan keuangan, di mana kesalahan dalam menilai kelayakan kredit dapat mengakibatkan kerugian finansial yang signifikan. Oleh karena itu, pengembangan model prediktif yang dapat memberikan hasil yang akurat sangat dibutuhkan.

Dengan menggunakan pendekatan klasifikasi, model ini bertujuan untuk mengidentifikasi pola dalam data historis dan memprediksi apakah seorang peminjam memiliki potensi untuk gagal bayar. Dengan menganalisis dan membandingkan performa dari algoritma XGBoost dan Random Forest dalam memprediksi risiko kredit berdasarkan dataset yang telah dikumpulkan, dengan demikian, penelitian ini bertujuan untuk menyediakan solusi berbasis machine learning yang dapat mendukung lembaga keuangan dalam mengambil keputusan yang lebih tepat dan efisien.

3.2. Pemilihan Dataset

Dataset yang digunakan dalam proyek ini adalah Credit Risk Dataset, yang menyajikan informasi terkait karakteristik peminjam dan status kredit mereka. Dataset ini terdiri dari beberapa sampel yang mencakup berbagai variable seperti **Tabel 1** sebagai berikut:

TABLE 1 Credit Risk Dataset Features

Feature Name	Description	Type
person_age	Usia peminjam. Semakin tua seseorang, biasanya semakin stabil kondisi finansialnya.	Integer
person_income	Pendapatan tahunan peminjam dalam satuan dolar.	Integer
person_home_ownership	Status kepemilikan rumah (RENT, MORTGAGE, OWN, dll.). Bisa menunjukkan stabilitas finansial.	Categorical
person_emp_length	Lama pengalaman kerja (dalam tahun). Bisa berpengaruh pada kemampuan membayar pinjaman.	Float

loan_intent	Tujuan pengajuan pinjaman (EDUCATION, MEDICAL, VENTURE, dll.).	Categorical
loan_grade	Klasifikasi risiko pinjaman dari A (terbaik) hingga G (terburuk).	Categorical
loan_amnt	Jumlah pinjaman yang diajukan.	Integer
loan_int_rate	Suku bunga pinjaman dalam persentase.	Float
loan_status	Status pembayaran pinjaman (biasanya 0 untuk lancar, 1 untuk gagal bayar).	Integer
loan_percent_income	Persentase pinjaman terhadap pendapatan peminjam.	Float
cb_person_default_on_file	Indikator apakah peminjam pernah gagal bayar sebelumnya (Y atau N).	Categorical
cb_person_cred_hist_length	Lama riwayat kredit dalam tahun.	Integer

Dataset yang digunakan dalam analisis ini terdiri dari 32.581 baris dan 12 kolom, yang mencakup berbagai informasi terkait peminjam dan pinjaman mereka. Kolom-kolom dalam dataset terbagi menjadi dua jenis utama, yaitu kategorikal dan numerik. Terdapat 4 kolom kategorikal, yaitu person_home_ownership, loan_intent, loan_grade, dan cb_person_default_on_file, yang berisi data dalam bentuk kategori seperti jenis kepemilikan rumah atau riwayat kredit. Sementara itu, terdapat 8 kolom numerik, yaitu person_age, person_income, person_emp_length, loan_amnt, loan_int_rate, loan_status, loan_percent_income, dan cb_person_cred_hist_length, yang berisi informasi kuantitatif seperti usia peminjam, pendapatan, dan jumlah pinjaman.

Dataset ini diperoleh dari sumber GitHub dan telah digunakan dalam berbagai penelitian mengenai analisis risiko kredit. Dengan jumlah data yang cukup besar dan komprehensif, dataset ini memungkinkan eksplorasi mendalam terhadap faktor-faktor yang mempengaruhi kelayakan kredit. Selain itu, dataset ini juga menghadirkan tantangan dalam menangani masalah ketidakseimbangan kelas, yang sering ditemui dalam masalah prediksi risiko kredit, sehingga pemilihan algoritma yang tepat menjadi kunci dalam keberhasilan model prediktif.

BAB 4

EXPLORATORY DATA ANALYSIS

Exploratory Data Analysis (EDA) adalah proses untuk menganalisis dataset secara visual dan statistik dengan tujuan untuk mendapatkan wawasan tentang pola, tren, atau hubungan dalam data. Dalam proyek ini, EDA dilakukan untuk mempersiapkan dataset sebelum membangun model prediktif menggunakan algoritma XGBoost. Beberapa langkah yang dilakukan dalam EDA antara lain adalah menganalisis statistik deskriptif, mengidentifikasi nilai yang hilang, mendeteksi outlier, dan memvisualisasikan hubungan antar variabel.

4.1. Analisis Statistik Deskriptif

TABLE II Statistik Deskriptif

	count	mean	std	min	max	25%	50%	75%
person_age	32581	27.73	6.35	20	144	23	26	30
person_income	32581	66074.85	61983.12	4000	6000000	38500	55000	79200
person_emp_length	31686	4.79	4.14	0	123	2	4	7
loan_amnt	32581	9589.37	6322.09	500	35000	5000	8000	12200
loan_int_rate	29465	11.01	3.24	5.42	23.22	7.9	10.99	13.47
loan_status	32581	0.22	0.41	0	1	0	0	0
loan_percent_income	32581	0.17	0.11	0	0.83	0.09	0.15	0.23
cb_person_cred_hist_length	32581	5.8	4.06	2	30	3	4	8

Statistik deskriptif memberikan gambaran yang komprehensif mengenai distribusi data dan karakteristik utama pada setiap variabel. Berdasarkan **TABEL II** statistik deskriptif yang diperoleh, dapat disimpulkan bahwa nilai mean untuk beberapa variabel penting seperti person_age adalah 27,73 tahun dengan standar deviasi sebesar 6,35, yang menunjukkan bahwa sebagian besar peminjam berada dalam rentang usia sekitar rata-rata. Variabel loan_amnt (jumlah pinjaman) memiliki nilai mean 9589,37 dengan standar deviasi sebesar 6322,09, mengindikasikan adanya variasi yang signifikan dalam jumlah pinjaman yang diajukan. Sementara itu, loan_int_rate (tingkat bunga pinjaman) menunjukkan nilai mean sebesar 11,01%, yang menggambarkan tingkat bunga rata-rata yang dikenakan pada peminjam. Selain itu, kolom loan_amnt memiliki nilai maksimum yang cukup besar, yaitu 35.000, yang mungkin perlu dicermati lebih lanjut terkait distribusi data yang ekstrem.

4.2. Identifikasi Nilai yang Hilang

TABLE III Missing Value


	Missing Values
person_age	0
person_income	0
person_home_ownership	0
person_emp_length	887
loan_intent	0
loan_grade	0
loan_amnt	0
loan_int_rate	3095
loan_status	0
loan_percent_income	0
cb_person_default_on_file	0
cb_person_cred_hist_length	0

Proses identifikasi nilai yang hilang merupakan langkah penting dalam EDA, karena keberadaan data yang hilang dapat memengaruhi kualitas model prediktif. Berdasarkan analisis nilai yang hilang, pada **TABEL III** variabel `person_emp_length` memiliki 887 nilai yang hilang, sementara `loan_int_rate` memiliki 3095 nilai yang hilang. Penanganan nilai yang hilang perlu dilakukan dengan hati-hati, misalnya melalui imputasi atau penghapusan data yang tidak lengkap, untuk mencegah bias pada model.

4.3. Identifikasi Outlier

Outlier, atau nilai ekstrim yang jauh berbeda dari sebagian besar data lainnya, dapat memengaruhi kinerja model secara signifikan. Oleh karena itu, deteksi dan penanganan outlier menjadi langkah yang sangat penting. Melalui visualisasi menggunakan boxplot, dapat dilihat bahwa variabel `person_age` memiliki nilai yang sangat ekstrem, yaitu usia peminjam mencapai 144 tahun, yang jelas merupakan outlier dan perlu dikaji lebih lanjut. Demikian pula, variabel `loan_int_rate` dan `loan_amnt` juga menunjukkan adanya nilai ekstrim yang dapat mempengaruhi analisis lebih lanjut.

Gambar berikut menunjukkan visualisasi boxplot untuk beberapa variabel, menggambarkan distribusi data dan identifikasi outlier:




Gambar 4. 1 Boxplot Identifikasi Outlier

4.4. Korelasi Antar Variabel

Matriks korelasi memberikan wawasan yang berharga mengenai hubungan antar variabel numerik dalam dataset. Dari heatmap korelasi yang dihasilkan, terlihat bahwa beberapa variabel menunjukkan korelasi yang signifikan. Sebagai contoh, `person_age` memiliki korelasi yang sangat kuat dengan `cb_person_cred_hist_length` (0,86), yang mengindikasikan bahwa usia peminjam berhubungan erat dengan panjang riwayat kredit mereka. Korelasi yang cukup signifikan juga terlihat antara `loan_amnt` (jumlah pinjaman) dan `loan_int_rate` (tingkat bunga pinjaman), serta `loan_percent_income`, yang menunjukkan bahwa semakin besar jumlah pinjaman yang diajukan, semakin tinggi pula tingkat bunga yang dikenakan dan proporsi pendapatan yang digunakan untuk pembayaran pinjaman.

Gambar berikut menunjukkan matriks korelasi yang menggambarkan hubungan antar variabel dalam dataset:



Gambar 4. 2 Heatmap Correlation

BAB 5

PREPROCESSING

5.1. Menangani Nilai yang Hilang

Dalam analisis data, keberadaan nilai yang hilang (missing values) merupakan tantangan yang dapat memengaruhi kualitas model machine learning. Menurut Little & Rubin (2019), terdapat tiga jenis mekanisme nilai yang hilang, yaitu Missing Completely at Random (MCAR), Missing at Random (MAR), dan Missing Not at Random (MNAR). MCAR terjadi ketika hilangnya data tidak berhubungan dengan variabel apa pun, MAR terjadi ketika nilai yang hilang bergantung pada variabel yang diamati, dan MNAR terjadi ketika nilai yang hilang bergantung pada nilai yang tidak diamati.

Dalam dataset ini, nilai yang hilang ditemukan pada variabel `loan_int_rate` dan `person_emp_length`. Untuk menangani nilai yang hilang, digunakan metode imputasi median. Pemilihan median dilakukan karena lebih tahan terhadap outlier dibandingkan dengan mean (Acuna & Rodriguez, 2004).

5.2. Outlier Handling

Outlier merupakan nilai ekstrem dalam dataset yang dapat memengaruhi distribusi data dan performa model. Menurut Aguinis et al. (2013), outlier dapat disebabkan oleh kesalahan pengukuran, variasi alami, atau anomali yang valid. Salah satu metode umum untuk menangani outlier adalah Interquartile Range (IQR), yang menghitung rentang antara kuartil pertama (Q1) dan kuartil ketiga (Q3). Data yang berada di luar batas $Q1 - 1.5 * IQR$ atau $Q3 + 1.5 * IQR$ dianggap sebagai outlier dan dihapus dari dataset.

5.3. Feature Engineering

Feature engineering merupakan proses menciptakan fitur baru dari fitur yang sudah ada untuk meningkatkan performa model (Kuhn & Johnson, 2013). Dalam proyek ini, beberapa fitur tambahan diciptakan berdasarkan hubungan antara pinjaman, pendapatan, dan lama bekerja:

1. Loan-to-income ratio: Perbandingan jumlah pinjaman terhadap pendapatan peminjam.

2. Loan-to-employment length ratio: Perbandingan lama pengalaman kerja dengan jumlah pinjaman.
3. Interest rate-to-loan amount ratio: Perbandingan suku bunga terhadap jumlah pinjaman.

5.4. Data Binning

Binning adalah teknik untuk mengubah variabel numerik menjadi kategori. Hal ini dapat meningkatkan interpretabilitas model dan mengurangi efek noise pada data (Dougherty et al., 1995). Dalam proyek ini, dilakukan binning pada variabel pendapatan (person_income) dan jumlah pinjaman (loan_amnt).

5.5. Data Encoding

Data encoding diperlukan untuk mengonversi variabel kategorikal menjadi bentuk numerik agar dapat diproses oleh algoritma machine learning (James et al., 2013). Dalam proyek ini, digunakan dua metode utama:

1. One-Hot Encoding untuk fitur tanpa urutan inheren, seperti person_home_ownership dan loan_intent.
2. Label Encoding untuk fitur dengan skala ordinal, seperti loan_grade dan cb_person_default_on_file.

5.7. Data Scaling

Feature scaling penting untuk memastikan bahwa semua fitur memiliki skala yang sebanding, sehingga algoritma machine learning dapat bekerja dengan lebih optimal (Han et al., 2011). Digunakan StandardScaler untuk menstandarkan fitur numerik ke dalam distribusi normal dengan mean 0 dan varians 1.

5.8. Handling Imbalance Target Data

Proses identifikasi nilai yang hilang merupakan langkah penting dalam EDA, karena keberadaan data yang hilang dapat memengaruhi kualitas model prediktif. Berdasarkan analisis nilai yang hilang, pada **TABEL III** variabel person_emp_length memiliki 887 nilai yang hilang, sementara loan_int_rate memiliki 3095 nilai yang hilang. Penanganan nilai yang hilang perlu dilakukan dengan hati-hati, misalnya melalui imputasi atau penghapusan data yang tidak lengkap, untuk mencegah bias pada model.

BAB 7

SPLITTING DATASET

Setelah melakukan preprocessing data, langkah selanjutnya adalah membagi dataset menjadi bagian yang berbeda untuk keperluan pelatihan (training), validasi (validation), dan pengujian (testing). Pembagian dataset ini sangat penting untuk memastikan bahwa model yang dibangun dapat bekerja dengan baik pada data yang belum pernah dilihat sebelumnya.

7.1. Konsep Splitting Dataset

Dalam machine learning, dataset perlu dibagi menjadi beberapa subset untuk menghindari masalah overfitting atau underfitting. Pembagian ini umumnya terdiri dari:

1. Data Training (Train Set): Digunakan untuk melatih model agar dapat mempelajari pola dari data. Biasanya, bagian terbesar dari dataset dialokasikan untuk pelatihan, sekitar 70-80%.
2. Data Validasi (Validation Set): Digunakan untuk mengevaluasi performa model selama proses pelatihan dan membantu dalam penyesuaian hyperparameter. Biasanya dialokasikan sekitar 10-15% dari dataset.
3. Data Uji (Test Set): Digunakan untuk menguji performa akhir model setelah pelatihan selesai. Data ini tidak pernah dilihat oleh model selama pelatihan. Biasanya dialokasikan sekitar 10-15% dari dataset.

7.2. Implementasi Splitting Dataset

Dalam penelitian ini, dataset dibagi dengan rasio 70:15:15 untuk training, validation, dan testing menggunakan `train_test_split` dari Scikit-learn.

```
from sklearn.model_selection import train_test_split

X = df_balanced.drop(columns=['loan_status'])
y = df_balanced['loan_status']

X_train, X_temp, y_train, y_temp = train_test_split(X, y,
test_size=0.3, random_state=42, stratify=y)
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp,
test_size=0.5, random_state=42, stratify=y_temp)


# Cek ukuran dataset
print("Distribusi Data Train:", X_train.shape)
print("Distribusi Data Val:", X_val.shape)
print("Distribusi Data Test:", X_test.shape)
```

BAB 8

PEMILIHAN MODEL

8.1. Arsitektur Model XGBoost

Dalam pengerjaan proyek ini yaitu analisis resiko kredit, agar prediksi apakah peminjam akan memenuhi kewajiban pinjamannya atau tidak maka dibutuhkan untuk memilih algoritma pembelajaran mesin yang tepat. Disini saya memilih XGBoost (Extreme Gradient Boosting) karena algoritmanya yang menawarkan kinerja prediktif yang unggul dengan efisiensi komputasi tinggi. Berikut ini penjelasan dari arsitektur algoritma XGBoost (Extreme Gradient Boosting) yang telah saya buat :



Gambar 8. 3 Model XGBoost

1. Credit Risk Dataset : Prosesnya dimulai dengan menginput Credit Risk Dataset, yang merupakan kumpulan fitur yang akan digunakan untuk membangun model nanti.
2. Ensemble Learning dengan Decision Tree : XGBoost adalah algoritma yang berbasis boosting, yang berarti dia membangun model secara bertahap. Model ini terdiri dari beberapa pohon keputusan (decision trees) yang bekerja sama untuk membuat prediksi yang lebih akurat. Di gambar, kita bisa lihat ada

beberapa pohon yang dilabeli Tree1, Tree2, ..., Tree k, yang menunjukkan bahwa model ini terdiri dari kumpulan pohon yang terus berkembang.


3. Residual dan Pembelajaran Bertahap : Setelah satu pohon dibuat, model akan menghitung residual error, yaitu selisih antara prediksi model dengan nilai asli yang seharusnya. Pohon berikutnya kemudian dibangun untuk memperbaiki kesalahan ini. Proses ini berlangsung secara bertahap, di mana setiap pohon baru berusaha mengurangi kesalahan dari pohon sebelumnya.
4. Prediksi Akhir : Setelah semua pohon dibuat, hasil akhirnya bukan cuma dari satu pohon saja, tapi merupakan gabungan dari semua pohon yang telah dilatih. Secara matematis, hasil prediksi model ini bisa dituliskan sebagai $\sum f_k(X, \theta_k)$ yang berarti semua output dari setiap pohon dijumlahkan untuk menghasilkan prediksi akhir. Dengan cara ini, model bisa memberikan hasil yang jauh lebih akurat dibandingkan hanya mengandalkan satu pohon saja.

Jadi, XGBoost (Extreme Gradient Boosting) adalah algoritma pembelajaran mesin berbasis ensemble yang dirancang untuk meningkatkan akurasi prediksi melalui penggabungan sejumlah pohon keputusan. Algoritma ini dikenal karena efisiensinya dalam komputasi dan kemampuannya menangani berbagai jenis data, termasuk yang memiliki ketidakseimbangan kelas.

8.2. Alasan Pemilihan Model

1. Efisiensi dan Skalabilitas: XGBoost dirancang untuk efisiensi komputasi tinggi, mampu menangani dataset besar dengan cepat.
2. Regularisasi: Algoritma ini memiliki mekanisme regularisasi bawaan yang membantu mencegah overfitting, memastikan model generalisasi dengan baik pada data baru.
3. Kinerja Unggul: Studi menunjukkan bahwa XGBoost sering kali mengungguli algoritma lain dalam tugas klasifikasi, termasuk prediksi risiko kredit. Misalnya, penelitian oleh Chen dan Guestrin (2016) menunjukkan bahwa XGBoost menawarkan kinerja dan efisiensi yang superior dalam berbagai aplikasi.

8.3. Arsitektur Model XGBoost



Gambar 8. 4 Model Random Forest

Arsitektur model Random Forest ini menggunakan teknik ensemble learning, di mana beberapa pohon keputusan (decision trees) dibangun dan digabungkan untuk memberikan prediksi yang lebih baik. Prosesnya dimulai dengan pembagian dataset menjadi beberapa bagian, yang masing-masing digunakan untuk melatih pohon keputusan yang berbeda. Setiap pohon memberikan hasil prediksi (Result-1, Result-2, hingga Result-N). Kemudian, hasil dari semua pohon ini digabungkan menggunakan teknik majority voting atau averaging, tergantung pada jenis masalah (klasifikasi atau regresi). Hasil akhir yang diperoleh merupakan keputusan dari mayoritas pohon, yang memastikan prediksi yang lebih stabil dan akurat dibandingkan dengan hanya mengandalkan satu pohon saja.

BAB 9

PELATIHAN MODEL

9.1. Proses Pelatihan Model XGBoost

Proses pelatihan dilakukan menggunakan algoritma XGBoost Classifier, yang merupakan salah satu varian dari Gradient Boosting Decision Trees (GBDT). Algoritma ini bekerja dengan membangun sejumlah pohon keputusan secara iteratif, di mana setiap pohon mencoba memperbaiki kesalahan dari pohon sebelumnya.

Parameter utama yang digunakan dalam pelatihan model ini antara lain:

1. `random_state=42`, Menetapkan nilai acak agar hasil yang diperoleh dapat direproduksi.
2. `eval_set=[(X_val, y_val)]`, Menggunakan data validasi untuk mengevaluasi performa model selama pelatihan.
3. `verbose=True`, Menampilkan informasi proses pelatihan, seperti error pada setiap iterasi.

Kode yang digunakan untuk pelatihan model adalah sebagai berikut:

```
from xgboost import XGBClassifier

# Inisialisasi model XGBoost
XGB = XGBClassifier(random_state=42)

# Latih model dengan data training dan validasi
XGB.fit(X_train, y_train, eval_set=[(X_val, y_val)],
        verbose=True)

# Prediksi pada data test dan validation
y_pred_val = XGB.predict(X_val)
y_pred_test = XGB.predict(X_test)
y_pred_train = XGB.predict(X_train)
```

9.2. Proses Pelatihan Model Random Forest

Proses pelatihan pada algoritma Random Forest Classifier dilakukan dengan menggunakan sejumlah pohon keputusan yang dibangun secara paralel. Setiap

pohon dalam model ini bekerja secara independen dan memberikan prediksi masing-masing, yang kemudian digabungkan untuk mendapatkan hasil akhir.

Kode yang digunakan untuk pelatihan model adalah sebagai berikut:

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score,
classification_report, confusion_matrix

rf_model = RandomForestClassifier(random_state=42)

# Latih model dengan data training
rf_model.fit(X_train, y_train)

# Prediksi pada data test dan validation
y_pred_valrf = rf_model.predict(X_val)
y_pred_testrf = rf_model.predict(X_test)
y_pred_trainrf = rf_model.predict(X_train)
```

BAB 10

EVALUASI DAN ANALISIS HASIL

10.1. Metrik Evaluasi

Evaluasi model dilakukan menggunakan beberapa metrik untuk mengukur performa model terhadap data validasi dan data uji. Metrik evaluasi yang digunakan dalam penelitian ini meliputi:

1. Akurasi (Accuracy): Mengukur persentase prediksi yang benar dari keseluruhan data.
2. Presisi (Precision): Mengukur seberapa banyak dari prediksi positif yang benar-benar positif.
3. Recall (Sensitivity): Mengukur seberapa banyak data positif yang benar-benar berhasil diklasifikasikan dengan benar oleh model.
4. F1-Score: Rata-rata harmonik dari precision dan recall untuk memberikan gambaran lebih seimbang terhadap performa model.
5. Confusion Matrix: Menampilkan jumlah prediksi yang benar dan salah untuk setiap kelas.

10.2. Evaluasi dan Analisis Hasil (Sebelum Tuning)

1. Classification Report

TABLE IV Classification Report XGBoost dan Random Forest

Model	Dataset	Precision (0)	Recall (0)	F1-Score (0)	Precision (1)	Recall (1)	F1-Score (1)	Accuracy
XGB	Train	0.942151	0.998070	0.969305	0.997949	0.938721	0.967429	0.968395
	Val	0.932216	0.986903	0.958781	0.986083	0.928221	0.956277	0.957566
	Test	0.925198	0.988813	0.955948	0.987987	0.920055	0.952812	0.954434
RF	Train	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
	Val	0.928331	0.978990	0.952988	0.977771	0.924400	0.950337	0.951699
	Test	0.913176	0.981446	0.946081	0.979947	0.906685	0.941893	0.944065

Hasil evaluasi menunjukkan bahwa kedua model, XGBoost (XGB) dan Random Forest (RF), memiliki performa yang sangat baik, namun dengan perbedaan kinerja yang signifikan. XGBoost menunjukkan akurasi yang stabil dan kemampuan lebih baik dalam menangani kelas minoritas (kelas 1), dengan recall dan F1-score yang tinggi, meskipun ada sedikit penurunan pada recall kelas 1 pada data uji. Di sisi lain, Random Forest mencapai kinerja sempurna pada data pelatihan, namun mengalami penurunan akurasi dan recall untuk kelas 1 pada data

validasi dan pengujian, meskipun akurasi keseluruhan tetap tinggi. Secara keseluruhan, XGBoost lebih unggul dalam hal stabilitas dan sensitivitas terhadap kelas 1, yang penting dalam prediksi risiko kredit.

2. Confussion Matrix

TABLE V Confussion Matrix XGBoost dan Random Forest

Model	Dataset	TP	TN	FP	FN
XGB	Train	16054	17068	33	1048
	Val	3401	3617	48	263
	Test	3372	3624	41	293
RF	Train	17102	17101	0	0
	Val	3387	3588	77	277
	Test	3323	3597	68	342

Hasil confusion matrix menunjukkan bahwa kedua model, XGBoost (XGB) dan Random Forest (RF), memiliki performa yang sangat baik dalam mengklasifikasikan data, namun dengan beberapa perbedaan. Pada XGBoost, model berhasil mendeteksi sebagian besar kasus positif dan negatif dengan baik pada data pelatihan, validasi, dan pengujian, meskipun ada beberapa false negatives (FN) pada data uji dan validasi, yang menunjukkan model sedikit kesulitan dalam mengidentifikasi semua sampel positif. Sementara itu, Random Forest menunjukkan false positives (FP) yang sangat rendah pada data pelatihan, namun terdapat peningkatan FP pada data validasi dan pengujian, yang berarti model cenderung sedikit lebih banyak salah dalam mengklasifikasikan kelas negatif sebagai positif pada data yang belum terlihat. Secara keseluruhan, kedua model menunjukkan kinerja yang sangat baik, namun XGBoost lebih baik dalam menghindari kesalahan besar pada data baru.

10.3. Hyperparameter Tuning

Setelah melakukan pelatihan awal dan evaluasi performa model XGBoost dan Random Forest, langkah selanjutnya adalah melakukan fine-tuning hyperparameter untuk mengoptimalkan kinerja masing-masing model. Fine-tuning bertujuan untuk mencari kombinasi parameter terbaik yang dapat meningkatkan akurasi, recall, precision, dan F1-score, serta meminimalkan overfitting atau underfitting. Proses ini dilakukan melakukan tuning sebanyak tiga kali untuk masing masing model secara manual. Berikut adalah daftar hyperparameter yang akan diuji pada masing-masing model:

TABLE VI Hyperparameter XGBoost dan Random Forest

Model	Hyperparameter	T1	T2	T3
XGB	n_estimators	300	500	750
	learning_rate	0.05	0.07	0.1
	max_depth	3	5	6
	Subsample	0.8	0.9	1.0
	colsample_bytree	0.8	0.9	1.0
	random_state	42	42	42
RF	n_estimators	250	500	750
	max_depth	3	5	8
	min_samples_split	10	15	20
	min_samples_leaf	4	5	10
	max_features	'sqrt'	'sqrt'	'sqrt'
	Random_state	42	42	42

10.4. Evaluasi dan Analisis Hasil (Setelah Tuning)

1. Classification Report

TABLE VII Classification Report XGBoost dan Random Forest

Model	Dataset	Precision (0)	Recall (0)	F1-Score (0)	Precision (1)	Recall (1)	F1-Score (1)	Accuracy
XGB T1	Train	0.892658	0.955558	0.923038	0.952192	0.885101	0.917422	0.920329
	Val	0.899590	0.958254	0.927996	0.955328	0.893013	0.923120	0.925638
	Test	0.893595	0.955525	0.923523	0.952213	0.886221	0.918033	0.920873
XGB T2	Train	0.933585	0.997895	0.964669	0.997739	0.929014	0.962151	0.963453
	Val	0.931282	0.990996	0.960212	0.990376	0.926856	0.957564	0.958930
	Test	0.923761	0.991814	0.956579	0.991163	0.918145	0.953258	0.954980
XGB T3	Train	0.972080	0.999649	0.985672	0.999639	0.971290	0.985261	0.985469
	Val	0.936660	0.988540	0.961901	0.987865	0.933133	0.959719	0.960840
	Test	0.929176	0.987995	0.957683	0.987183	0.924693	0.954917	0.956344
RF T1	Train	0.776967	0.890825	0.830010	0.872088	0.744299	0.803142	0.817560
	Val	0.781116	0.893861	0.833694	0.875917	0.749454	0.807766	0.821667
	Test	0.775841	0.886767	0.827604	0.867876	0.743793	0.801058	0.815280
RF T2	Train	0.807397	0.917783	0.859059	0.904768	0.781078	0.838386	0.849428
	Val	0.813600	0.920600	0.863799	0.908548	0.789028	0.844581	0.854823
	Test	0.804578	0.911050	0.854511	0.897484	0.778718	0.833893	0.844884
RF T3	Train	0.817360	0.941056	0.874857	0.930550	0.789732	0.854378	0.865392
	Val	0.822815	0.942701	0.878688	0.932907	0.796943	0.859582	0.869832
	Test	0.815114	0.935880	0.871332	0.924728	0.787722	0.850744	0.861801

Dari hasil evaluasi model XGBoost (XGB) dan Random Forest (RF), dapat disimpulkan bahwa meskipun Tuning 3 pada XGBoost memberikan akurasi tertinggi, Tuning 2 lebih unggul dalam hal kestabilan performa di seluruh dataset (train, val, test). Pada XGBoost Tuning 2, precision, recall, dan F1-score untuk kedua kelas (0 dan 1) tetap konsisten dengan hasil yang sangat baik, mencerminkan kemampuan model untuk memberikan prediksi yang stabil pada berbagai data, dengan akurasi yang hampir setara dengan Tuning 3 (0.960840 di val dan 0.954980 di test). Keunggulan Tuning 2 ini terlihat karena meskipun tidak mencapai nilai tertinggi pada T3, model ini lebih tangguh dalam menghadapi fluktuasi pada dataset yang berbeda, menunjukkan kestabilan yang lebih baik.

Sementara itu, Random Forest (RF) meskipun menunjukkan kinerja yang solid, tetap memiliki kelemahan dalam hal konsistensi antara dataset training, validasi, dan testing. RF Tuning 3 menghasilkan akurasi tertinggi (0.861801 di test), tetapi tidak sebaik XGBoost dalam hal kestabilan performa di seluruh dataset. Selain itu, RF cenderung memiliki akurasi yang lebih rendah dan kesulitan dalam menangani ketidakseimbangan kelas dibandingkan XGBoost, yang lebih baik dalam mengidentifikasi kelas minoritas dengan lebih sensitif. Oleh karena itu, meskipun Tuning 3 pada XGBoost memberikan akurasi tertinggi, Tuning 2 pada XGBoost lebih direkomendasikan untuk aplikasi yang membutuhkan stabilitas dan performa yang konsisten.

2. Confussion Matrix (Setelah Tuning)

TABLE VIII Confussion Matrix XGBoost dan Random Forest

Model	Tuning	Data Train				Data Validation				Data Test			
		TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN
XGB	Tuning 1	15137	16341	760	1965	3272	3512	153	392	3248	3502	163	417
	Tuning 2	15888	17065	36	1214	3396	3632	33	268	3365	3635	30	300
	Tuning 3	16611	17095	6	491	3419	3623	42	245	3389	3621	44	276
RF	Tuning 1	12729	15234	1867	4373	2746	3276	389	918	2726	3250	415	939
	Tuning 2	13358	15695	1406	3744	2891	3374	291	773	2854	3339	326	811
	Tuning 3	13506	16093	1008	3596	2920	3455	210	744	2887	3430	235	778


Meskipun Tuning 3 pada XGBoost memberikan hasil tertinggi dalam hal True Positives (TP) dan False Negatives (FN), Tuning 2 justru lebih unggul dalam hal stabilitas performa. Tuning 2 memberikan True Positives (TP) yang sangat baik (15,888) dan False Negatives (FN) yang lebih rendah (1,214) dibandingkan dengan Tuning 1, sementara False Positives (FP) tetap terjaga rendah (36), menunjukkan bahwa model ini tetap efisien dalam menghindari kesalahan klasifikasi. Keunggulan Tuning 2 terletak pada kemampuannya untuk memberikan kinerja yang lebih konsisten di seluruh dataset (train, val, test) tanpa fluktuasi yang signifikan, yang penting dalam aplikasi dunia nyata seperti prediksi risiko kredit. Dibandingkan dengan Random Forest (RF), XGBoost Tuning 2 menunjukkan hasil yang lebih baik dalam mendeteksi kelas positif, dengan TP yang lebih tinggi dan FN yang lebih rendah. Secara keseluruhan, meskipun Tuning 3 memberikan akurasi tertinggi, Tuning 2 lebih direkomendasikan karena lebih stabil dan dapat diandalkan di berbagai dataset.

BAB 11

INTERPRETASI DAN VISUALISASI

11.1. Feature Importance


1. XGBoost Tuning-2 Feature Importance



Gambar 11. 5 XGBoost Tuning-2 Feature Importance

Berdasarkan hasil feature importance pada XGBoost Tuning 2, fitur `loan_to_income_ratio` memiliki kontribusi terbesar dalam model dengan F score tertinggi (1274), menunjukkan bahwa rasio pinjaman terhadap pendapatan peminjam adalah faktor paling berpengaruh dalam memprediksi risiko kredit. Fitur lainnya yang juga penting termasuk `loan_int_rate` (1193) dan `int_rate_to_loan_amt_ratio` (1191), yang menunjukkan bahwa tingkat bunga pinjaman dan rasio antara suku bunga dengan jumlah pinjaman turut mempengaruhi keputusan model. Fitur lain seperti `person_age` (910) dan `person_emp_length` (868) juga memberikan kontribusi signifikan, menunjukkan bahwa usia peminjam dan lama pengalaman kerja mempengaruhi risiko kredit. Sementara itu, fitur `person_home_ownership_RENT` memiliki kontribusi yang paling rendah (218), menunjukkan bahwa status kepemilikan rumah sebagai faktor kategorikal tidak memiliki pengaruh besar dalam model ini. Analisis ini memberikan wawasan bahwa model XGBoost lebih mengutamakan fitur finansial dan pengalaman peminjam dalam menentukan risiko kredit.


2. Random Forest Tuning-3 Feature Importance



Gambar 11. 6 Random Forest Tuning-3 Feature Importance

Berdasarkan hasil feature importance pada Random Forest Tuning 3, fitur `loan_amount_group_very_large` memiliki kontribusi terbesar dalam model dengan feature importance sekitar 0.22, menunjukkan bahwa ukuran pinjaman sangat berpengaruh dalam prediksi risiko kredit. Fitur lainnya yang juga penting termasuk `income_group_low-middle` dan `loan_to_income_ratio`, yang memiliki feature importance signifikan (masing-masing sekitar 0.15 dan 0.14), mengindikasikan bahwa kelompok pendapatan dan rasio pinjaman terhadap pendapatan juga berperan besar dalam menentukan risiko kredit. Fitur seperti `loan_int_rate`, `loan_percent_income`, dan `cb_person_cred_hist_length` juga menunjukkan kontribusi yang cukup besar, dengan feature importance lebih dari 0.05, yang menggambarkan bahwa tingkat bunga pinjaman, persentase pinjaman terhadap pendapatan, dan riwayat kredit peminjam juga mempengaruhi keputusan model. Secara keseluruhan, model Random Forest memberikan perhatian yang lebih besar pada variabel finansial dan karakteristik peminjam, namun tidak terlalu bergantung pada fitur demografis seperti usia peminjam atau status kepemilikan rumah.


11.2. Perbandingan Akurasi Semua Model



Gambar 11. 7 Perbandingan Akurasi Semua Model

Berdasarkan grafik perbandingan akurasi antara model XGBoost dan Random Forest (RF), XGBoost Tuning 2 dipilih sebagai model yang lebih stabil meskipun Tuning 3 menunjukkan akurasi tertinggi pada training data. XGBoost Tuning 2 memberikan performa yang konsisten pada data training, validation, dan test, dengan akurasi yang hampir seragam di semua dataset (sekitar 0.950-0.960), menunjukkan bahwa model ini lebih dapat diandalkan pada data yang tidak terlihat sebelumnya. Sementara itu, Random Forest memiliki akurasi yang lebih rendah secara keseluruhan, dengan RF Default menunjukkan performa yang jauh di bawah XGBoost Tuning 2, terutama pada data testing. Meskipun RF Tuning 3 mengalami peningkatan, kinerjanya masih kurang stabil dibandingkan dengan XGBoost Tuning 2 yang menunjukkan kestabilan lebih baik di seluruh dataset. Oleh karena itu, XGBoost Tuning 2 lebih direkomendasikan untuk aplikasi yang membutuhkan akurasi yang stabil dan dapat diandalkan.

11.3. ROC Curve (Test Set)



Gambar 11. 8 ROC Curve

Visualisasi ROC Curve menunjukkan bahwa model XGBoost secara konsisten memberikan performa klasifikasi yang unggul dibandingkan Random Forest, dengan nilai AUC tertinggi dicapai oleh XGBoost Tuning 3 (0.986), diikuti oleh XGBoost Tuning 2 (0.984) dan XGBoost Default (0.983). Meskipun Random Forest Default juga menunjukkan hasil yang sangat baik (AUC 0.985), beberapa versi tuning justru mengalami penurunan performa, seperti Tuning 1 (0.892). Hal ini menegaskan bahwa tuning tidak selalu meningkatkan akurasi model, dan XGBoost terbukti lebih stabil dan andal dalam mendeteksi risiko gagal bayar kredit pada dataset ini.

BAB 12

KESIMPULAN DAN SARAN

12.1. Kesimpulan

Berdasarkan hasil penelitian mengenai penerapan algoritma XGBoost dan Random Forest dalam memprediksi risiko kredit, dapat disimpulkan bahwa kedua model tersebut berhasil diterapkan untuk mengklasifikasikan risiko kredit dengan baik, meskipun XGBoost menunjukkan kinerja yang lebih unggul dalam hal kestabilan dan akurasi. Proses penerapan machine learning menggunakan kedua algoritma ini melibatkan tahap-tahap seperti pemilihan dataset, pelatihan model, evaluasi dengan berbagai metrik (seperti akurasi, precision, recall, F1-score), serta interpretasi hasil menggunakan visualisasi fitur penting.

Dalam perbandingan kinerja antara XGBoost dan Random Forest, XGBoost Tuning 2 menunjukkan hasil yang lebih stabil dan lebih baik dalam mengidentifikasi kelas positif (debitur berisiko gagal bayar) dibandingkan dengan Random Forest, meskipun Tuning 3 pada XGBoost memiliki akurasi tertinggi. Random Forest cenderung memiliki performa yang lebih rendah, terutama pada data testing, dengan akurasi yang lebih bervariasi antara training, validation, dan testing.

Adapun fitur-fitur yang paling berpengaruh dalam penentuan risiko kredit berdasarkan interpretasi dan visualisasi adalah `loan_to_income_ratio`, `loan_int_rate`, dan `int_rate_to_loan_amt_ratio` pada XGBoost, yang menunjukkan bahwa faktor finansial, seperti rasio pinjaman terhadap pendapatan dan suku bunga, sangat mempengaruhi keputusan model. Sedangkan pada Random Forest, fitur seperti `loan_amount_group` dan `income_group` memiliki kontribusi terbesar, menunjukkan bahwa informasi mengenai kelompok pinjaman dan pendapatan juga memegang peranan penting dalam memprediksi risiko kredit.

Secara keseluruhan, XGBoost Tuning 2 lebih direkomendasikan untuk digunakan dalam memprediksi risiko kredit karena memberikan keseimbangan terbaik antara akurasi stabil dan kemampuan model untuk mengidentifikasi fitur-fitur yang signifikan dalam menentukan risiko kredit.

12.2. Saran

1. **Peningkatan Kualitas Data:** Untuk meningkatkan akurasi model, sangat penting untuk terus memperbaiki kualitas data yang digunakan, seperti menangani data yang hilang, outlier, dan ketidakseimbangan kelas. Penggunaan teknik oversampling atau undersampling dapat dicoba untuk mengatasi masalah ketidakseimbangan kelas, terutama pada data yang memiliki proporsi tinggi antara peminjam lancar dan peminjam gagal bayar.
2. **Optimasi Hyperparameter:** Meskipun Tuning 2 pada XGBoost memberikan hasil yang stabil, pengoptimalan lebih lanjut terhadap hyperparameter model, seperti learning rate, max_depth, dan n_estimators, dapat lebih meningkatkan kinerja model. Penggunaan teknik seperti Grid Search atau Random Search untuk mencari kombinasi parameter yang optimal perlu dipertimbangkan.
3. **Ensemble Learning:** Penggunaan teknik ensemble learning yang menggabungkan kekuatan beberapa model, seperti Stacking atau Boosting, dapat dicoba untuk meningkatkan hasil prediksi. Menggabungkan model XGBoost dengan model lain, seperti LightGBM atau CatBoost, dapat memberikan hasil yang lebih baik dengan memanfaatkan kekuatan masing-masing model.